

PROPOSAL FINAL PROJECT: ANALISIS DATA PUBLIK

Mata Kuliah: Pengantar Big Data | **Program Studi:** Sistem Informasi

Tugas: Tugas Kelompok 1 (Fondasi Penelitian dan Persetujuan Dataset)

Komponen Informasi	Keterangan
Judul Proyek	Analisis Jumlah Sekolah, Guru, dan Murid Berdasarkan Jenis Sekolah di DKI Jakarta Tahun 2022
Kelompok	Kelompok 11
Anggota Tim & NIM	1. Dini Nitakaini (NIM: 2410631250009) 2. Dwi Endah Saumi (NIM: 2410631250010)
Tautan Repositori GitHub	1. https://github.com/dinitakaini/bigdata-dki-education-2022 (nanti ubah lgi)
Release / Tag GitHub	https://github.com/dinitakaini/bigdata-dki-education-2022/releases/tag/tugas-1 (nanti ubah lgi)

1. Fondasi Penelitian (Problem Formulation & Analytical Framework)

1.1 Judul Penelitian

Analisis Jumlah Sekolah, Guru, dan Murid Berdasarkan Jenis Sekolah di DKI Jakarta Tahun 2022.

1.2 Latar Belakang & Perumusan Masalah

Pendidikan merupakan salah satu faktor penting dalam meningkatkan kualitas sumber daya manusia dan mendukung pencapaian Tujuan Pembangunan Berkelanjutan (SDG 4: Quality Education). Sebagai pusat ekonomi dan pemerintahan Indonesia, Provinsi DKI Jakarta memiliki ekosistem pendidikan yang cukup besar dan beragam. Namun, masih terdapat permasalahan dalam pemerataan sumber daya pendidikan, terutama dalam hal jumlah tenaga pengajar dan daya tampung sekolah pada berbagai jenjang

dan jenis pendidikan, seperti SD, SMP, SMA, SMK, madrasah di bawah naungan Kementerian Agama, serta Sekolah Luar Biasa (SLB).

Untuk melihat kondisi tersebut, dapat digunakan beberapa indikator, seperti Rasio Murid terhadap Guru (Student-Teacher Ratio/STR) dan Rasio Murid terhadap Sekolah (Student-School Ratio/SSR). STR menunjukkan perbandingan jumlah murid dengan jumlah guru yang dapat memberikan gambaran mengenai beban kerja tenaga pengajar, sedangkan SSR menunjukkan perbandingan jumlah murid dengan jumlah sekolah yang dapat menggambarkan daya tampung sekolah. Namun, kajian yang membahas hubungan dan pengelompokan beban pendidikan antarjenis sekolah di DKI Jakarta masih belum banyak dilakukan, khususnya dengan menggunakan analisis berbasis komputasi dan data terbuka. Oleh karena itu, penelitian ini dilakukan untuk menganalisis dan mengelompokkan kondisi beban pendidikan pada berbagai kategori sekolah di DKI Jakarta berdasarkan data tahun 2022.

1.3 Tujuan Penelitian

1. Mengetahui gambaran umum dan pola persebaran jumlah sekolah, guru, dan peserta didik di DKI Jakarta berdasarkan jenis sekolah pada tahun 2022.
2. Menganalisis Rasio Murid-Guru (Student-Teacher Ratio/STR) pada setiap jenis sekolah serta membandingkannya dengan standar ideal pelayanan pendidikan yang berlaku.
3. Menerapkan metode *unsupervised clustering* untuk mengelompokkan jenjang atau jenis sekolah berdasarkan kondisi fasilitas dan jumlah tenaga pengajar yang tersedia.
4. Memberikan informasi dan rekomendasi berdasarkan hasil analisis data yang dapat menjadi bahan pertimbangan bagi pemerintah maupun masyarakat dalam memahami kondisi pendidikan di DKI Jakarta.

1.4 Pertanyaan Analitik (Analytical Questions)

- **Deskriptif:** Bagaimana persebaran jumlah sekolah, guru, dan peserta didik berdasarkan jenis sekolah, seperti TK, SD, SMP, SMA, SMK, SLB, RA, MI, MTs, dan MA di Provinsi DKI Jakarta pada tahun 2022?
- **Komparatif/Rasio:** Jenis sekolah mana yang memiliki rasio murid dan guru paling tinggi dan paling rendah? Apakah rasio tersebut sudah sesuai dengan standar pelayanan pendidikan yang berlaku?
- **Lanjutan (*Clustering* dan *Relasional*):** Bagaimana pengelompokan jenis sekolah berdasarkan jumlah sekolah, guru, dan peserta didik menggunakan metode *clustering*? Selain itu, apakah jumlah sekolah memiliki hubungan dengan jumlah guru yang tersedia?

1.5 Unit Analisis

Unit analisis pada proyek ini adalah kategori jenis/jenjang pendidikan di wilayah Provinsi DKI Jakarta pada tahun kalender akademik 2022.

1.6 Pengguna Hasil (Stakeholders)

- **Dinas Pendidikan Provinsi DKI Jakarta:** Dapat menggunakan data sebagai bahan evaluasi untuk melihat pemerataan jumlah dan formasi guru serta membantu dalam perencanaan daya tampung sekolah berdasarkan zonasi.
- **Kementerian Agama Provinsi DKI Jakarta:** Dapat memanfaatkan data untuk mengevaluasi beban dan rasio pendidik pada madrasah, mulai dari RA, MI, MTs, hingga MA.
- **Peneliti dan Akademisi:** Data dapat menjadi sumber referensi dalam melakukan penelitian dan analisis kebijakan publik, khususnya yang berkaitan dengan pendidikan dan pemanfaatan *open public data*.
- **Masyarakat Umum dan Komite Sekolah:** Data dapat digunakan untuk mengetahui kondisi mutu layanan pendidikan dan ketersediaan fasilitas sekolah di daerah, sehingga dapat meningkatkan transparansi dan partisipasi masyarakat.

2. Metadata Dataset Publik

Komponen	Keterangan Rinci
Nama Dataset	Data Jumlah Sekolah, Guru, dan Murid Menurut Jenis Sekolah di Provinsi DKI Jakarta Tahun 2022
Penerbit	Dinas Pendidikan Provinsi DKI Jakarta / Portal Satu Data Indonesia & Satu Data Jakarta
URL Sumber	1. https://data.go.id/dataset/dataset/jumlah-sekolah-guru-dan-murid-menurut-jenis-sekolah-tahun-2022 2. https://satudata.jakarta.go.id/open-data/detail?kategori=dataset&page_url=jumlah-sekolah-guru-dan-murid-menurut-jenis-sekolah&data_no=1
Lisensi	Open Data Commons Open Database License (ODbL) / Lisensi Terbuka Pemerintah Indonesia
Versi Dataset	Versi 1.0 (Rilis Resmi Tahunan Rekapitulasi 2022)
Tanggal Akses	6 September 2026

Periode Data	Tahun 2022
Format Data	CSV (Comma-Separated Values) & XLSX
Atribut Utama	• jenis_sekolah (Kategorikal/String): Jenjang satuan pendidikan • jumlah_sekolah (Numerik/Integer): Total unit gedung/sekolah terdata • jumlah_guru (Numerik/Integer): Total tenaga pengajar aktif • jumlah_murid (Numerik/Integer): Total peserta didik terdaftar
Atribut Hasil Rekayasa	• rasio_guru_murid ($STR = \text{jumlah_murid} / \text{jumlah_guru}$) • rata_murid_per_sekolah ($SSR = \text{jumlah_murid} / \text{jumlah_sekolah}$) • rata_guru_per_sekolah ($\text{jumlah_guru} / \text{jumlah_sekolah}$)
Target Variabel	Tidak ada label tunggal terikat (Eksplorasi & Pemodelan Tanpa Supervisi/Unsupervised).

3. Tata Kelola Data: Alasan Pemilihan, Bias, Sensitivitas, dan Lisensi

3.1 Alasan Pemilihan Dataset

Dataset ini memiliki tingkat validitas institusional yang tinggi karena bersumber langsung dari pemerintah daerah. Karakter datanya ringkas, bersih, dan memuat indikator esensial yang memungkinkan kalkulasi beban kerja pendidik serta kapasitas sekolah antarsektor tanpa memerlukan imputasi data yang berlebihan.

3.2 Potensi Bias

- **Keterbatasan Agregasi Wilayah:** Data disajikan secara makro di tingkat provinsi, sehingga menyembunyikan kesenjangan antarkotamadya (contoh: Kepulauan Seribu versus Jakarta Selatan).
- **Keterbatasan Status Sekolah :** Data tidak memisahkan sekolah berstatus negeri dan swasta, padahal kedua kelompok memiliki dinamika pembiayaan dan ketersediaan pengajar yang berbeda.
- **Keterbatasan Data Guru :** Variabel jumlah_guru belum memerinci status kepegawaian (ASN, PPPK, atau honorer).

3.3 Sensitivitas & Perlindungan Data Pribadi

Dataset ini adalah data agregat publik yang tidak mencakup data pribadi sensitif (*non-PII*), seperti nama guru/siswa, nomor induk kependudukan (NIK), atau informasi tempat tinggal. Dengan demikian, dataset ini berkategori risiko rendah dan mematuhi kaidah UU No. 27 Tahun 2022 tentang Pelindungan Data Pribadi.

3.4 Izin Redistribusi melalui GitHub

Berdasarkan ketentuan lisensi data terbuka pemerintah, data ini dapat didistribusikan kembali di repositori publik GitHub untuk kepentingan riset dan pendidikan, dengan kewajiban mencantumkan atribusi sumber asli pada berkas README.md dan LICENSE.

4. Landasan Teori & Penelitian Terdahulu

4.1 Landasan Teori

- **Education Production Function (Hanushek, 1986):** Teori ekonomi pendidikan yang menyatakan bahwa kualitas capaian pendidikan dipengaruhi secara signifikan oleh ketersediaan faktor input fisik dan nonfisik, khususnya proporsi guru terhadap peserta didik.
- **Standar Pelayanan Minimal (SPM) Pendidikan (Permendikbud No. 32/2018):** Menetapkan batas ambang ideal rasio murid terhadap guru berkisar antara 1:15 hingga 1:20 untuk jenjang sekolah dasar dan menengah.
- **Analisis Klaster Berbasis Jarak Euclidean:** Pendekatan komputasi untuk mengelompokkan jenis sekolah berdasarkan kemiripan vektor kapasitas dan beban ajar secara objektif.

4.2 Tinjauan Penelitian Terdahulu

Peneliti & Tahun	Topik & Fokus	Metode & Temuan Relevan
Prasetyo & Wibowo (2021)	Disparitas Rasio Tenaga Pendidik di Area Metropolitan	Metode deskriptif spasial; menemukan ketimpangan rasio paling tinggi terkonsentrasi pada jenjang kejuruan dan madrasah swasta.
Sari et al. (2020)	Clustering Profil Sekolah Terbuka dengan K-Means	Membuktikan efektivitas clustering 3 kelompok dalam membedakan jenjang yang

		mengalami defisit maupun surplus pengajar secara visual.
UNESCO UIS (2022)	Benchmark Ratio Evaluasi Kota Megapolitan Asia Tenggara	Menyoroti fenomena lonjakan peserta didik jenjang menengah atas yang kerap tidak diimbangi pemenuhan kuota guru mata pelajaran keahlian khusus.

5. Metodologi Analisis, Jadwal, dan Pembagian Tugas

5.1 Kerangka Analisis & Rekayasa Fitur

Metodologi mengikuti tahapan standar CRISP-DM (pemahaman domain, pemahaman data, persiapan data, eksplorasi/pemodelan, dan evaluasi). Variabel baru dihitung menggunakan formula:

Rasio Murid-Guru (STR) = $\text{jumlah_murid} / \text{jumlah_guru}$

Kapasitas Rata-Rata Sekolah (SSR) = $\text{jumlah_murid} / \text{jumlah_sekolah}$

Rata-Rata Guru per Sekolah = $\text{jumlah_guru} / \text{jumlah_sekolah}$

5.2 Rencana Visualisasi Data

- **Bar Chart Komparatif:** Membandingkan volume peserta didik dan guru per jenis jenjang.
- **Scatter Plot & Bubble Chart:** Menampilkan hubungan antara jumlah sekolah vs jumlah murid, dengan ukuran lingkaran menunjukkan besaran STR.
- **Correlation Heatmap:** Matriks korelasi Pearson antarseluruh variabel numerik dan rasio turunan.
- **Benchmark Line Chart:** Membandingkan STR aktual tiap jenjang terhadap batas ambang batas nasional (1:20).

5.3 Metode Analitik Lanjutan & Baseline

- **Baseline:** *Rule-Based Classification* untuk mengelompokkan kategori sekolah berdasarkan deviasi SPM (Defisit Guru, Ideal, Surplus Guru).
- **Metode Lanjutan:** *K-Means Clustering* dan *Hierarchical Agglomerative Clustering (HAC)* pada fitur terstandarisasi untuk mengidentifikasi klaster beban secara otomatis.
- **Metode Regresi:** *Ordinary Least Squares (OLS)* untuk memodelkan daya serap guru terhadap pertambahan jumlah sekolah.

5.4 Metrik Evaluasi

- **Silhouette Coefficient & Elbow Method (Inertia):** Mengukur kekompakan dan keterpisahan kluster yang terbentuk (target Silhouette Score > 0.55).
- **Integritas Data:** Pengecekan nilai kosong (null check), validasi tipe data numerik, dan tidak adanya anomali nilai negatif.

5.5 Jadwal Pelaksanaan Proyek (Timeline 5 Minggu)

Tahap Pelaksanaan	Minggu 1	Minggu 2	Minggu 3	Minggu 4	Minggu 5
1. Proposal & Persetujuan Dataset (Tugas 1)	✓				
2. Akuisisi, Pembersihan, & Validasi Data		✓			
3. Analisis Deskriptif & Visualisasi Data (EDA)		✓	✓		
4. Implementasi Clustering & Evaluasi Baseline			✓	✓	
5. Penyusunan Laporan Akhir & Tagging Release Final					✓

5.6 Pembagian Tugas Anggota Kelompok

Nama	Kontribusi pada Tugas
Dini Nitakaini	• Membuat dan mengatur struktur repositori GitHub untuk tugas kelompok. • Menyusun latar belakang masalah, tujuan penelitian, pertanyaan analitik, dan unit analisis. • Merancang metode analisis lanjutan menggunakan <i>clustering</i>, seperti K-Means dan HAC, serta evaluasi menggunakan <i>Silhouette Score</i>. • Menyusun Data Card yang berisi deskripsi dan informasi mengenai dataset yang digunakan. • Menggabungkan seluruh bagian tugas ke dalam naskah proposal.
Dwi Endah Saumi	• Mencari dan memvalidasi sumber dataset dari data terbuka, seperti Data.go.id dan Satu Data Jakarta. • Menyusun kajian pustaka, teori mengenai rasio pendidikan, serta penelitian terdahulu yang relevan. • Menganalisis kemungkinan bias pada dataset dan memperhatikan etika penggunaan data. • Merancang konsep visualisasi data yang akan digunakan dalam analisis. • Membantu menyusun pembagian tugas dan jadwal kerja kelompok.